

제조데이터 분석과 최적화

제조 데이터 기반 AI 개발 (소리 데이터)

김한진

gks359@cbnu.ac.kr

충북대학교 산업인공지능연구센터

CONTENTS

I

소리 데이터를 활용한 AI 개발 - 장비이상 조기탐지 AI

II

소리 데이터를 활용한 AI 개발 - MIMII

■ 소리 데이터를 활용한 AI 개발

➤ 열풍건조

목적 :

- ✓ 도금처리 이후 피막과 안정제가 금속 표면에 안정적으로 달라붙을 수 있게 하는 공정
- ✓ 탈수로 물기가 제거된 제품을 열풍건조 공정을 통과시킴으로써 표면의 물기를 완전히 건조



[열풍건조기]

■ 소리 데이터를 활용한 AI 개발

➤ 공정(설비)상의 문제 현황

- ✓ 열풍건조 설비를 가동하기 위해 상당한 전력이 소모, 높은 전력 소모 구조로 인해 설비의 고장이 드물지 않게 발생함
- ✓ 과열 방지를 위한 모터는 사전 설정된 적정값으로 회전하면서 고유 진동수 및 진동 패턴을 보유
- ✓ 그러나, 코일 문제나 기타 문제가 발생할 경우, 해당 고유 상태가 깨지면서 이상 현상을 일으킴

■ 소리 데이터를 활용한 AI 개발

➤ 열풍건조 설비 내 Sound 데이터

수집기간 : 2021.09.06~2021.10.27

수집주기 : 5sec

데이터 개수 :

- ✓ FAN Sound 불량 : 13개
- ✓ FAN Sound 정상 : 170개

■ 소리 데이터를 활용한 AI 개발


- 기계학습을 위해서는 소리가 가진 '핵심정보'를 압축하고 추출하여, 모델이 소화할 수 있는 수치형 데이터로 변환하는 Feature Extraction 과정이 필수

The Familiar

ID	Feature 1	Feature 2	Feature 3	Label
001	12.5	3.8	95.2	A
002	14.1	2.5	88.7	B
003	10.9	4.2	91.0	A
004	13.3	3.0	93.5	C

기존의 정형 데이터: 모델이 즉각적으로 수학적 패턴을 학습할 수 있는 명확한 구조.

The Challenge




소리 데이터: 시간에 따른 파동(Wave) 형태.
원본 음원 자체를 모델에 입력하는 것은 연산량이 기하급수적으로 증가하며 핵심 정보를 식별하기 어려움.

■ 소리 데이터를 활용한 AI 개발

➤ step1_eda.py

librosa : 오디오 데이터를 다룰 수 있는 음성 분석 패키지




■ 소리 데이터를 활용한 AI 개발

➤ 원본 사운드 파형(Time Domain) 분석


소리를 시간에 따른 진폭으로 시각화

시간 축의 파형만으로는 정상 팬과 고장난 팬의 미세한 패턴 차이를 구분하기 어려움

정상(OK) 사운드 파형




이상(Error) 사운드 파형



■ 소리 데이터를 활용한 AI 개발

➤ 푸리에 변환(FFT, Fast Fourier Transform)

신호를 소리의 높이(주파수)에 따라 분해하면 각 성분의 강도 확인 가능




■ 소리 데이터를 활용한 AI 개발


➤ 푸리에 변환(FFT, Fast Fourier Transform)

Half spectrum : 푸리에 변환을 통과한 결과는 대칭 구조로 나오기 때문에 중복 데이터를 피하고자 주파수의 절반만 사용

정상(OK) Half Spectrum




이상(Error) Half Spectrum



■ 소리 데이터를 활용한 AI 개발

➤ MFCC(Mel Frequency Cepstral Coefficient)


오디오 신호에서 사람의 청각 특성을 반영하여 특징을 추출
(인간의 달팽이관은 저주파(낮은 소리)의 변화에는 매우 민감하지만, 고주파(높은 소리)의 변화는 잘 구분하지 못하는 비선형적인 특성을 가짐)



■ 소리 데이터를 활용한 AI 개발

➤ MFCC(Mel Frequency Cepstral Coefficient)

오디오 신호에서 사람의 청각 특성을 반영하여 특징을 추출
(인간의 달팽이관은 저주파(낮은 소리)의 변화에는 매우 민감하지만, 고주파(높은 소리)의 변화는 잘 구분하지 못하는 비선형적인 특성을 가짐)




■ 소리 데이터를 활용한 AI 개발

➤ 상관분석 및 후진 소거법

상관분석 : 두 변수 간 선형적 또는 비선형적 관계가 얼마나 강한지 -1 ~ 1 사이의 값으로 확인

후진 소거법 : 상관관계가 낮은 변수는 제거하여 모델 성능을 높이는 기법





■ Decision Tree란?

- 의사결정 나무는 스무고개 놀이처럼, 데이터가 가진 속성(Feature)들을 기준으로 질문을 던져가며 데이터를 분류(Classification)하거나 값을 예측(Regression)하는 기계학습 알고리즘

뿌리 노드 (Root Node): 전체 데이터가 모여 있는 시작점

규칙 노드 (Internal/Decision Node): 데이터를 분할하는 기준(질문)이 되는 지점

잎 노드 (Leaf/Terminal Node): 최종적으로 분류된 결과 또는 예측 값



■ Decision Tree란?

- “어떤 변수를 기준으로, 어떤 값에서 분기해야 데이터를 가장 잘 분류할 수 있을까?”를 수학적으로 결정해야함 → 평가지표 중 하나로 Entropy를 사용

Entropy란?

데이터의 '불순도(Impurity)' 또는 '불확실성(Uncertainty)' 측정하는 지표

예.

특정 노드에 '정상' 데이터만 100% 존재한다면, 불확실성이 없으므로 엔트로피는 0
반대로 '정상'과 '이상' 데이터가 50:50으로 섞여 있다면(불확실성 최대), 엔트로피는 1

의사결정나무의 궁극적인 목표는 데이터가 가진 엔트로피(불확실성)를 0으로 만드는 것



노드를 분할할 때, "분할하기 전의 엔트로피"와 "분할한 후 자식 노드들의 엔트로피
가중평균"의 차이를 계산

→ 이 차이를 정보 이득(Information Gain)이라 하며, 모델은 정보 이득이 최대가 되는
방향으로 노드를 분할함

■ Decision Tree란?


➤ 특징

- 1) 모델 결과를 해석하기 쉬움(화이트 박스 모델) → 산업 현장에서 엔지니어가 납득할 수 있는 근거자료
- 2) 적은 데이터로도 유의미한 패턴 추출 가능




■ 특징 분포 분석

- AI가 오분류한 샘플의 특징값(feature value)이 실제 정답 클래스의 평균과 가까운지, 아니면 오판한 클래스의 평균과 가까운지 시각화 ('mfcc_min', 'mfcc_max', 'spectrum_min' 으로 후진 소거법을 한다면...)





■ Confidence에 따라 시스템 관리

- `model.predict_proba` 함수를 통해 판별에 대한 신뢰도(Confidence) 산출
→ 현장 엔지니어는 해당 값을 바탕으로 아래와 같은 비즈니스 로직 설계 가능



■ 소리 데이터를 활용한 AI 개발


- **MIMII**(Malfunctioning Industrial Machine Investigation and Inspection) 데이터셋
- 실제 제조 현장에서 가동되는 다양한 산업용 기계(밸브, 펌프, 팬, 슬라이더 등)의 정상 및 비정상(고장) 소음 데이터를 모아 놓은 오픈소스 데이터셋
 - 데이터 불균형 상황에서 기계의 이상 징후를 사전 포착하는 예지보전 AI 연구의 표준 벤치마크로 활용



■ 소리 데이터를 활용한 AI 개발


➤ 주파수 영역 변환, STFT

- Short Time Furrier Transform : 시간에 따라 어떤 주파수 성분을 가지는지 추출
→ 2차원 평면(시간 x 주파수)에 나타낸 스펙트로그램 도출
(단순한 진폭의 변화가 아닌, 특정 시간에 발생하는 이상 주파수 패턴을 학습)



STFT 변환
신호 내부 주파수 성분
분리

2차원 평면 (Time X Frequency)으로 매핑(스펙트로그램)




색상의
진하기는
소리의 크기
(에너지)

■ 소리 데이터를 활용한 AI 개발

➤ 스펙트로그램 변환 비교


- 스펙트로그램이란? STFT를 거쳐 나온 결과물



■ 소리 데이터를 활용한 AI 개발

➤ Spectrogram과 Mel-Spectrogram

- STFT 수행하여 얻은 스펙트로그램에 Mel Filterbank 곱함(저주파/고주파 특성)
- Mel-Spectrogram의 장점(인간의 청각 인지 모방, 고주파 노이즈 억제)




[정상 valve]

[비정상 valve]

■ 소리 데이터를 활용한 AI 개발

➤ 데이터 변환 파이프라인 시각화 결과




■ 소리 데이터를 활용한 AI 개발

➤ CNN 기반 오토인코더, 합성곱 오토인코더

- 2D 이미지(Mel-Spectrogram)로 변환한 음향 데이터를 활용하여 모델 학습


주파수영역 :
128개의 Band
(세로)

시간영역 :
128프레임
(가로)



■ 소리 데이터를 활용한 AI 개발

➤ 복원 오차(MSE) 분포 시각화 및 분석



[연구적 분석]

두 분포가 멀리 떨어져
있을수록(Separability) 모델의 특징
추출 능력이 우수함을 의미

[연구적 단서]

분포가 겹치는 구간은 모델의 Latent
Space 최적화가 더 필요하거나,
소음에 대한 전처리가 요구된다는
신호

■ 소리 데이터를 활용한 AI 개발

➤ Confusion Matrix

- 현장 도입 시 발생할 수 있는 실제 오진율과 예지보전 성공률 예상

		예측 결과 (Predicted)	
		정상 (Normal)	비정상 (Abnormal)
실제 상태 (Actual)	정상 (Normal)	정상 가동 유지	불필요한 점검 (비용 낭비)
	비정상 (Abnormal)	치명적인 고장 누락 (위험)	성공적인 예지보전

■ 소리 데이터를 활용한 AI 개발

➤ 오토 인코더의 정상/비정상 처리 메커니즘 비교

구 분	정상 데이터	비정상 데이터
입력 패턴	학습된 익숙한 주파수	처음보는 낯선 주파수
디코더 동작	패턴을 그대로 통과 및 복원	낯선 패턴을 ‘정상’의 형태로 강제 변환
출력 결과	원본과 거의 일치	이상 발생 부위가 유실
최종 MSE 결과	낮은 오차 (Low MSE) → 정상 판정	높은 오차 (High MSE) → 이상 판정

감사합니다

Q&A

